

CONVENIO PLUS TI — UNIVERSIDAD DEL VALLE 2025

Trabajo Teórico-Práctico 1

Detección de Fraude en Tarjetas de Crédito: Métricas Custom y Modelo Federado

Guatemala, junio de 2026

1. Resumen

El presente trabajo aborda dos objetivos complementarios en el ámbito de la detección de fraude bancario. El Objetivo A explora métricas de evaluación personalizadas (feval) en LightGBM para reducir falsos positivos y, de forma específica para el grupo, maximizar el monto de fraude recuperado en USD. El Objetivo B desarrolla un modelo federado que, entrenado sobre datos de dos bancos latinoamericanos (Bolivia y Brasil), realiza inferencias sobre un tercer banco guatemalteco sin contar con sus etiquetas.

Los tres conjuntos de datos provienen del estándar ISO 8583 y cubren aproximadamente 100,000 transacciones cada uno, correspondientes al primer semestre de 2025. Se diseñaron cuatro variables de comportamiento por cliente aplicadas de forma consistente en todos los datasets, y se eliminaron sistemáticamente las columnas de identidad bancaria para garantizar la generalización cross-banco. El modelo federado seleccionado (FedAvg Simulado) alcanzó un AUC-ROC de 0.886 y un recall de 90% en el test de junio, recuperando el 96.58% del monto total en riesgo. A partir de este modelo se generaron tres inferencias sobre Banco 3 que exploran distintas estrategias de combinación y calibración del umbral; dado que Banco 3 no posee etiquetas, el umbral se recalibró asumiendo una prevalencia de fraude regional cercana al 5%, corrigiendo la sobreestimación causada por el distribution shift de montos. Para el objetivo específico del grupo, el modelo P6-M6 (sample weight proporcional a la raíz del monto) logra rescatar el 97.70% del valor en juego.

2. Metodología

El flujo de trabajo se organizó en cinco etapas secuenciales aplicadas a los tres bancos:

Análisis Exploratorio de Datos (EDA): carga y verificación de estructura, análisis de balanceo de clases, estudio de distribuciones de monto (amount_usd), patrones temporales y correlaciones con la variable objetivo. Los notebooks de Banco 1 y Banco 2 incluyen análisis de fraude; el de Banco 3 se enfoca en compatibilidad estructural y distribution shift respecto a los bancos de entrenamiento.

Ingeniería de Variables: construcción de cuatro variables de comportamiento derivadas de la secuencia temporal de transacciones por cliente (descritas en la sección 3.2), aplicadas mediante la misma función a los tres datasets para garantizar consistencia.

Generación del Dataset Federado: unión de Banco 1 y Banco 2 tras eliminar 13 columnas de identidad bancaria (bank_code, bank_country, monedas locales, identificadores institucionales). Partición temporal: entrenamiento en meses 1 a 5 (167,778 filas) y test en junio (32,055 filas).

Modelado Objetivo A: entrenamiento de siete modelos LightGBM sobre el dataset de Banco 1, con diferentes funciones feval personalizadas. Tres modelos (Base y P4) apuntan a minimizar FP ratio fijando recall $\geq 90\%$; cuatro modelos (P6) buscan maximizar el monto salvado en USD mediante distintas penalizaciones económicas.

Modelado Objetivo B: dos estrategias federadas — Modelo A (dataset unificado BO+BR entrenado como un solo LightGBM) y Modelo B (FedAvg simulado: modelos independientes por banco cuyas probabilidades se promedian). Sobre Banco 3 se generaron tres inferencias federadas: (V1) promedio 50/50 con umbral operativo, (V2) promedio 50/50 con umbral recalibrado a una tasa de fraude $\sim 5\%$, y (V3) combinación ponderada por el AUC de cada banco con umbral recalibrado. La inferencia se entrega para el primer 30% y el 100% del Banco 3.

3. Descripción de la Implementación Práctica

3.1 EDA y Hallazgos Principales

Los tres datasets siguen el estándar ISO 8583 con 66 columnas originales, de las cuales cuatro están completamente vacías (100% nulos) y fueron eliminadas. El balanceo de clases es el siguiente:

Dataset	Filas	Fraudes	Tasa	Período
Banco 1 — BO VIP (Bolivia)	100,003	4,919	4.92%	Ene–Jun 2025
Banco 2 — BR Privado (Brasil)	100,000	3,205	3.21%	Ene–Jun 2025
Banco 3 — GT Estatal (Guatemala)	100,000	Sin etiqueta	—	2025 (inferencia)
Dataset Federado (BO + BR)	200,003	8,124	4.06%	Ene–Jun 2025

El hallazgo más relevante del EDA es común a los dos bancos etiquetados: los fraudes se concentran en montos altos. En Banco 1, la mediana de una transacción fraudulenta (~USD 800) es aproximadamente 4 veces mayor que la de una legítima (~USD 200). En Banco 2, la relación se mantiene (~USD 350 vs ~USD 80). Este patrón justifica directamente el enfoque del grupo de maximizar monto salvado.

Banco 3 (Guatemala) presenta un distribution shift severo en monto: su mediana es USD 13.7, aproximadamente 10 veces menor que Banco 1 y 5 veces menor que Banco 2. Esto obligó a excluir el monto absoluto como feature del modelo federado y priorizar features relativas (amount_zscore_customer, amount_ratio_vs_baseline). Además el canal ECOM concentra la mayor tasa de fraude (8%), las transacciones nocturnas (0-5h) presentan mayor riesgo (~8%), y la correlación positiva entre txn_count_last_1h y fraude (r=0.41) es la señal más fuerte en el dataset federado.

3.2 Ingeniería de Variables

Se construyeron cuatro variables de comportamiento que se aplicaron de forma idéntica a los tres datasets. La implementación utiliza ventanas rodantes temporales (rolling windows) indexadas por client_id y datetime_tx, calculadas estrictamente con datos pasados (closed='left') para evitar data leakage:

Variable	Descripción	Señal observada
time_since_last_txn_min	Minutos transcurridos desde la transacción anterior del mismo cliente.	Valores bajos (ráfagas) correlacionan con fraude. Velocidad anómala de consumo.
txn_count_last_1h / 24h	Cantidad de transacciones del cliente en la última hora y en las últimas 24 horas (ventana rodante temporal).	Correlación con is_fraud de 0.41. Ráfagas de actividad son el indicador más fuerte en el dataset federado.
amount_zscore_customer	Z-score del monto de la transacción respecto al histórico del propio cliente (media y desviación estándar calculadas up-to-the-moment).	Correlación 0.19-0.26. Alta desviación implica transacción inusual para ese perfil de cliente.
amount_ratio_vs_baseline	Cociente entre el monto de la transacción y el baseline histórico del cliente (client_baseline_amount).	Correlación 0.26. Los fraudes tienen ratio medio de 0.69 vs 0.24 en transacciones legítimas. Feature agnóstica a la moneda del banco.

Para el modelo federado se agregaron cinco variables adicionales diseñadas para ser agnósticas al banco: amount_ratio_vs_baseline, is_night, velocity_x_zscore (velocidad por zscore), intl_high_zscore (internacional con zscore > 2) y velocity_ratio_1h_24h (ratio de velocidad normalizada). Estas mostraron correlaciones con is_fraud de hasta 0.40 en el dataset federado.

Para el Objetivo A (modelo centralizado de Banco 1) se recuperaron adicionalmente tres columnas eliminadas en el paso federado por razones de sesgo: DE9_conversion_rate_billing (magnitud de la internacionalidad), DE43_card_acceptor_name_location (identificador de comercio, útil en modelo centralizado) y client_id (solo durante el cálculo de features históricos, eliminado del feature set final). Se construyeron 8 features adicionales: amount_vs_max_historical, amount_ratio_vs_baseline, amount_percentile, is_high_amount (flag top 10%), is_night, ecom_high_amount, international_high_amount y amount_zscore_channel.

3.3 Dataset Federado

La construcción del dataset federado siguió tres pasos: (1) limpieza de cada banco con la misma función, produciendo 50 columnas por dataset; (2) eliminación de 13 columnas de sesgo jurisdiccional, reduciendo a 37 columnas comunes; (3) concatenación y mezcla aleatoria de ambos bancos (seed=42) obteniendo 200,003 filas. La partición temporal asigna los meses 1-5 al entrenamiento (167,778 filas, fraude 4.10%) y junio al test (32,055 filas, fraude 3.90%). La diferencia de 0.2 puntos porcentuales entre splits confirma ausencia de concept drift temporal. El modelo no puede ver bank_code, bank_country, monedas locales ni identificadores institucionales, garantizando que aprende patrones de comportamiento universales y no idiosincrasias de cada banco.

3.4 Objetivo A — Modelos con Métricas Personalizadas

El entrenamiento usa LightGBM v4.6 con GPU (Tesla T4 en Google Colab). Se aplica undersampling 10:1 solo en train (resultando en 27,819 filas, fraude 9.09%). El test cubre los meses 4, 5 y 6 (49,882 filas). Las variables aprobadas y response_description se excluyen del feature set por ser leakage operacional.

Paso 4 — Reducir FP ratio (punto común a todos los grupos): el threshold se fija como el valor más alto que garantiza recall >= 90%, según la curva precision-recall. Se compararon tres modelos:

Modelo	Threshold	AUC-ROC	Recall	Precision	FP Ratio	% Monto Salvado
Base — AUC-ROC	0.102	0.906	90.04%	9.35%	0.9065	96.65%
P4-M1 — feval_fp_ratio	0.070	0.902	90.04%	8.68%	0.9132	96.51%
P4-M2 — feval_balanced	0.056	0.902	90.04%	8.15%	0.9185	96.79%

Los tres modelos alcanzan exactamente recall = 90.04% (2,151 fraudes detectados de 2,389). La restriccion de recall = 90% actúa como un piso rígido: todos los modelos se calibran en ese punto de la curva precision-recall, resultando en cantidades elevadas de falsos positivos (entre 20,843 y 24,226) ya que la precisión a ese nivel de recall es naturalmente baja (8-9%). Curiosamente, el modelo Base supera a los dos modelos con feval personalizada en FP ratio. Esto evidencia que las funciones feval de Paso 4, diseñadas para minimizar FP durante el entrenamiento con un threshold interno fijo al percentil 95, no se alinean perfectamente con el threshold de recall externo aplicado en evaluación, generando un artefacto de optimización. Se selecciona el modelo Base como mejor de Paso 4 (FP Ratio = 0.9065).

Paso 6 — Maximizar monto salvado (objetivo del grupo): el threshold se selecciona maximizando la utilidad económica = suma(amount_usd de TP) - 5 x FP, sin restricción de recall. Se evaluaron cuatro funciones feval:

Modelo	Threshold	AUC-ROC	Recall	FP Ratio	Monto Salvado USD	% Monto
P6-M3 — High Value Precision	0.1299	0.903	82.42%	0.717	\$2,485,844	93.73%
P6-M4 — Economic Utility	0.1353	0.905	82.42%	0.699	\$2,484,320	93.67%
P6-M5 — Amount F-beta (β=2)	0.1394	0.903	82.54%	0.746	\$2,489,412	93.86%

P6-M6 — Sample Weight √amount*	0.1033	0.892	86.69%	0.881	\$2,591,238	97.70%
-----------------------------------	--------	-------	--------	-------	-------------	--------

- **Modelo seleccionado para el objetivo del grupo.** Los modelos P6-M3 a P6-M5 aplican distintas funciones de evaluación que ponderan montos, pero al optimizar el threshold por utilidad económica convergen a umbrales similares (~0.13) y resultados parecidos: recall cercano a 82%, FP entre 4,500 y 5,800, y monto salvado entre 93.7% y 93.9%. El modelo P6-M6 adopta un enfoque conceptualmente distinto: en lugar de modificar la señal de parada del entrenamiento vía feval, modifica la señal de aprendizaje directamente asignando `sample_weights = raiz(amount_usd)` a cada observación. Con esto, equivocarse en un fraude de USD 2,000 penaliza aproximadamente 4.5 veces más que en uno de USD 100 durante el cálculo del gradiente. El resultado es un recall más alto (86.7%) y el mayor porcentaje de monto salvado (97.70%), aunque con más falsos positivos (15,285).

3.5 Objetivo B — Modelo Federado

Se implementaron dos estrategias federadas, ambas entrenadas sobre los meses 1-5 del dataset federado (BO+BR) con undersampling 10:1 y evaluadas en el test de junio:

Modelo A (Dataset Unificado): un único LightGBM entrenado sobre los 167,778 registros combinados de ambos bancos. Usa `feval_amount_fp_weighted` como señal de parada (maximiza monto de TP ponderado por FP ratio). Los datos crudos de ambos bancos estarían disponibles en un mismo entorno, lo que requiere un acuerdo de privacidad entre instituciones.

Modelo B (FedAvg Simulado): cada banco entrena su LightGBM de forma independiente sobre sus propios datos (sin compartir registros crudos). Las probabilidades de fraude generadas sobre el test se promedian 50/50 (soft voting). Solo se intercambian predicciones, no datos.

Modelo	AUC-ROC	Recall	Precision	F1-Score	FP Ratio	% Monto Salvado
Modelo A — Dataset Unificado	0.8719	90.56%	5.70%	0.107	0.943	95.83%
Modelo B — FedAvg Simulado*	0.8858	90.00%	6.12%	0.114	0.939	96.58%

- **Modelo seleccionado.** El Modelo B supera al A en AUC-ROC (0.886 vs 0.872) y en monto salvado (96.58% vs 95.83%), con un FP ratio ligeramente menor (0.939 vs 0.943). Dado que el objetivo federado privilegia la privacidad, el Modelo B es doblemente preferible: mejores métricas y menor exposición de datos sensibles entre instituciones.

Inferencia sobre Banco 3 — Tres variantes federadas. Sobre Banco 3 se generaron tres inferencias federadas que exploran, en progresión, cómo combinar los bancos y cómo calibrar el umbral ante la ausencia de etiquetas:

Variante	Combinación de bancos Threshold	Fraude 30%	Fraude 100%
V1 — FedAvg base	Promedio 50/500.0757 (operativo)	40.48%	42.22%
V2 — FedAvg recalibrado	Promedio 50/500.1173 (calibrado ~5%)	5.02%	5.00%
V3 — FedAvg ponderado por AUC	onderado por AUC (0.557 / 0.443) 0.1094 (calibrado ~5%)	5.06%	5.00%

Comentado [FC1]: @VILLAFUERTE ARREDONDO MARIA JOSE En amarillo deje todo lo que leí de modelo federado. Está desactualizado con los últimos cambios hechos.

La V1 usa el umbral operativo calibrado en junio (recall 90%) y predice una tasa de fraude elevada (~42%), evidenciando el distribution shift: los montos de Banco 3 son aproximadamente 10 veces menores que los de los bancos de entrenamiento, lo que infla los `amount_zscore_customer` y dispara la señal de fraude. La V2 corrige esto recalibrando el umbral para marcar como fraude solo el 5% de transacciones con mayor score (prevalencia asumida similar a la regional de Bolivia/Brasil). La V3 mantiene esa calibración, pero, en lugar de promediar 50/50, pondera cada banco por su AUC individual en junio (Bolivia 0.8756 → peso 0.557; Brasil 0.6967 → peso 0.443), dando más peso al modelo que generaliza mejor. Las tres entregas se exportan con las columnas `transaction_id` + `is_fraud` ("Verdadero"/"Falso"), respetando el orden original del archivo de Banco 3, y el 30% corresponde a las primeras 30,000 transacciones de ese archivo.

4. Conclusiones

Para el objetivo de reducir falsos positivos manteniendo un recall cercano al 90%, el modelo Base mostró el mejor desempeño. Los resultados indican que las estrategias diseñadas específicamente para optimizar el FP Ratio no generaron mejoras adicionales cuando el umbral de decisión se ajustó posteriormente para cumplir con el requisito de recall establecido.

Por otro lado, para maximizar el monto recuperado por fraude, el modelo P6-M6 obtuvo los mejores resultados y representa la alternativa con mayor valor financiero. No obstante, este beneficio implica una mayor carga operativa debido al incremento de alertas generadas, por lo que modelos como P6-M4 pueden resultar más adecuados en escenarios con recursos de investigación limitados.

Respecto al enfoque federado, el Modelo B (FedAvg Simulado) superó al modelo unificado tanto en desempeño predictivo como en capacidad de preservar la privacidad de los datos. Los resultados demuestran que instituciones con perfiles de fraude distintos pueden colaborar de manera efectiva sin compartir información sensible, obteniendo modelos con mejor capacidad de generalización.

Finalmente, la evaluación sobre el Banco 3 evidenció un cambio de distribución importante respecto a los datos de entrenamiento, especialmente en los montos de transacción. La recalibración del umbral permitió corregir la sobreestimación inicial de fraude y producir predicciones más consistentes. Como trabajo futuro, se recomienda ajustar el modelo utilizando retroalimentación real del Banco 3 para mejorar su calibración y desempeño operativo.

5. Análisis de Resultados y Comparativo de Estrategias

El análisis cuantitativo identifica dos decisiones principales según el objetivo operativo del banco.

Reducción de falsos positivos. Forzar un recall elevado permite detectar más fraudes, pero genera una cantidad considerable de alertas falsas y un aumento importante en los costos operativos. En contraste, optimizar el umbral con base en la utilidad económica reduce significativamente los falsos positivos, manteniendo un nivel de detección que continúa siendo competitivo. Esto evidencia un compromiso entre maximizar la detección de fraude y controlar la carga operativa asociada a la investigación de alertas.

Monto salvado. Los modelos evaluados muestran que es posible recuperar una alta proporción del monto fraudulento con niveles moderados de falsos positivos. Sin embargo, uno de los modelos logra recuperar una fracción aún mayor del monto total a costa de incrementar el número de alertas generadas. Desde una perspectiva financiera, esta alternativa resulta más rentable siempre que el banco cuente con la capacidad operativa necesaria para gestionar el volumen adicional de casos.

Comparación entre enfoques federado y unificado. El modelo federado obtuvo un mejor desempeño que el modelo unificado, lo que sugiere que la combinación de modelos entrenados sobre distribuciones de fraude distintas aporta información complementaria y mejora la capacidad de generalización.

La principal limitación observada es el cambio de distribución en los montos de transacción entre los bancos utilizados para el entrenamiento y el Banco 3 de Guatemala. Este fenómeno provocó una sobreestimación inicial de la tasa de fraude, que pudo corregirse mediante una recalibración del umbral basada en la prevalencia esperada. Como trabajo futuro, se recomienda ajustar el modelo utilizando retroalimentación real del Banco 3 e incorporar técnicas de adaptación de dominio para mejorar su desempeño en nuevos entornos.